硕士研究生学位论文预答辩

基于可解释性深度学习的气象短时预测方法研究

学　　生：

指导老师：

目 录

- 研究目的及意义
- 研究现状
- 研究对象和内容
- 研究创新性
- 已取得的成果

研究目的及意义

气象预测对公共生活、农业与灾害防控具有关键支撑作用

公共安全与社会运行保障

精准预测风速、气温、湿度、云量等要素，有助于预警暴雨、高温、寒潮、大风等天气事件，保障交通、电力、医疗等公共系统的稳定运行。

农业生产与资源管理优化

气象预测可指导种植、灌溉、施肥、病虫害防治等农业决策，提高产量与资源利用效率，减少气候波动带来的损失。

灾害防控与风险管理能力提升

提前识别极端天气变化趋势，使政府与应急部门能够快速部署防灾措施，降低大风、洪涝、干旱、热浪等自然灾害的影响。

研究目的及意义

气象预测深度赋能水电站业务，发挥关键增效与保障作用

优化发电与调度计划

基于精准的降水与径流预报，科学制定蓄放水策略，实现水资源最大化利用，保证发电效益最优。

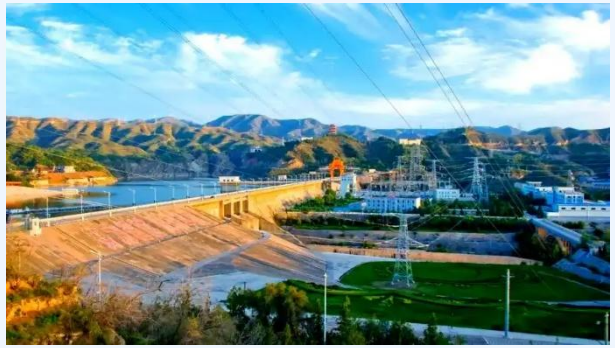

保障电网稳定运行

基于气温等气象数据，预测区域用电负荷变化，使水电站能灵活、快速地调整发电出力，平抑电网波动。

防范风险与安排运维

利用干旱期窗口检修设备，依据暴雨预警提前防洪，统筹安全与效益。

目 录

- 研究目的及意义
- 研究现状
- 研究对象和内容
- 研究创新性
- 已取得的成果

研究现状

传统数值预报依赖**求解大气动力学和热力方程**，通过**全球/区域模式模拟**未来大气状态

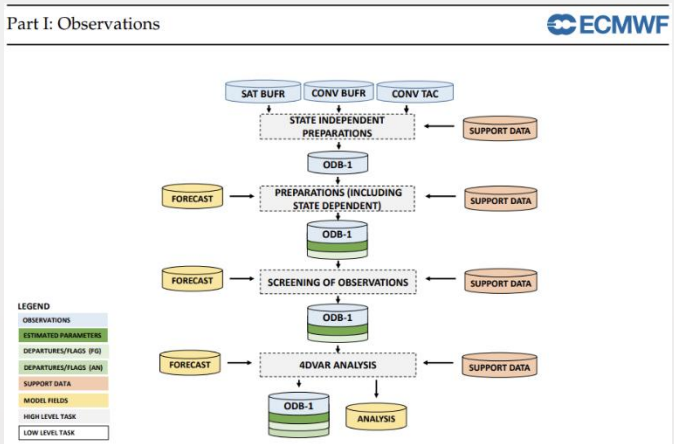

欧洲中期天气预报中心综合预报系统（IFS）

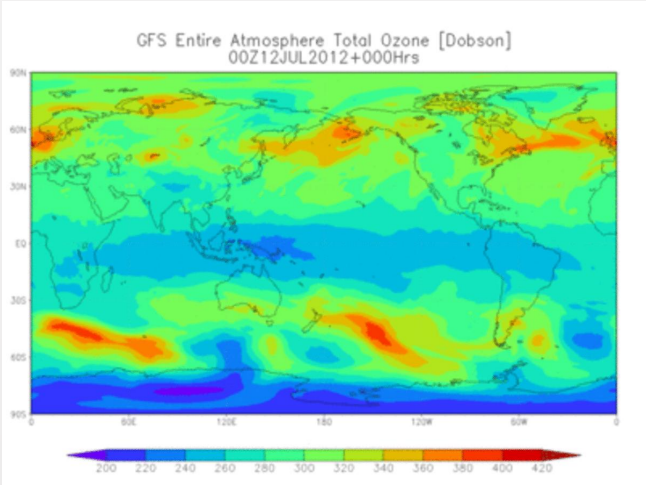

美国国家环境预报中心全球预报系统(GFS)

- **ECMWF IFS**：全球最高精度的谱–格点混合动力框架。
- **NCEP GFS**：美国业务化全球预报系统，采用有限体积 FV3 动力核心。

传统数值模型受限于参数化假设与计算成本，难以捕捉局地非线性特征

研究现状

深度学习气象预测利用大规模数据驱动模型学习大气场的时空演变，从而实现高效、快速的天气要素预测

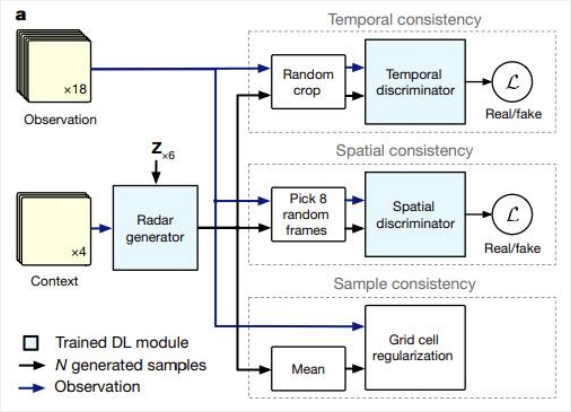

DGMR (2022 Nature)

Pangu Weather (2023 Nature)

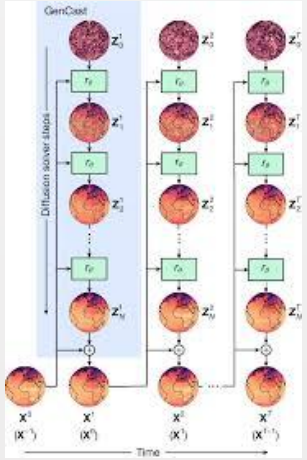

Gencast (2024 Nature)

- **DGMR**：利用深度生成模型实现短临降水预报。
- **Pangu Weather**：基于三维神经网络的全球数值天气预报模型，能够以极高速度生成中期高精度天气预测。
- **GenCast**：通过概率生成框架解决传统确定性预测中极端天气事件低估的问题。

深度学习模型常被批评为“黑箱”模型，缺乏物理解释性

研究现状

解决气象观测网络的**非均匀性**和**不规则性结构**，使用**图神经网络**将气象场表示为图

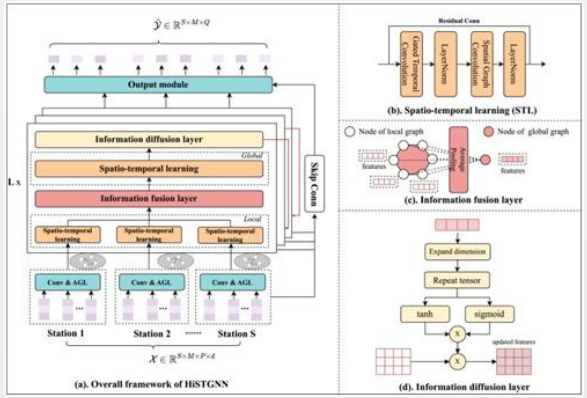

HiSTGNN (Information Sciences 2022)

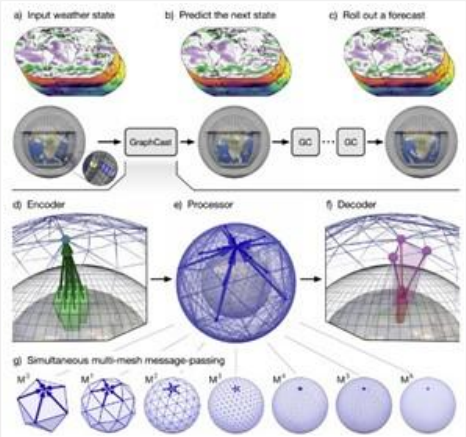

GraphCast (Science 2023)

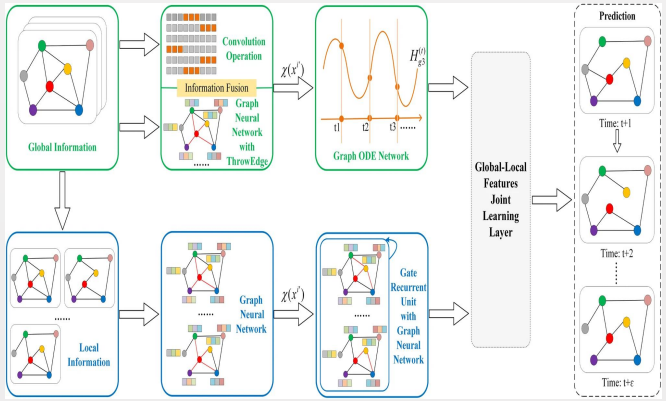

DSTGNN (TKDE 2024)

- **HiSTGNN**：构建层次时空图神经网络，用于同时捕捉跨站点的空间依赖和气象变量之间的交互，实现气象精准预测。
- **GraphCast**：采用图神经网络架构，从全球再分析数据中学习预测未来天气。
- **DSTGNN**：引入动态时空图卷积，能够实时捕获气象要素在时间和空间维度上的动态依赖关系。

传统图神经网络的两两关系建模框架仍可能难以全面刻画气象系统中普遍存在的复杂多站点空间相关性，同时缺乏一定的可解释性

目 录

- 研究目的及意义
- 研究现状
- 研究对象和内容
- 研究创新性
- 已取得的成果

研究对象——数据集

WeatherBench高分辨率天气数据集

- 包含**2048个**全球分布式节点，用于记录不同地区和不同分辨率下的真实天气观测数据
- 包含**温度、云量、湿度**和**地面风速**等气象要素
- 使用了从**2010年1月1日至2018年12月31日**的全球气象数据

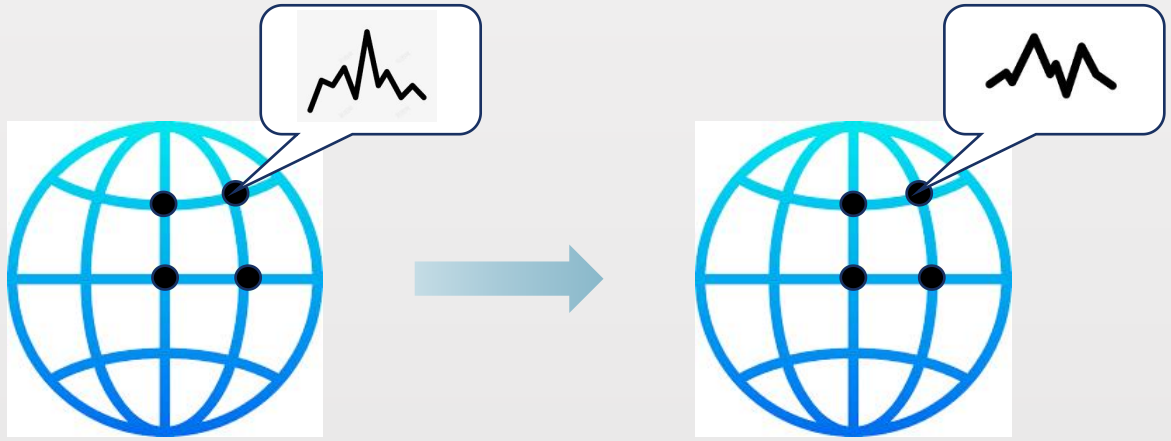

气象预测的目的是根据给定气象站经纬度位置$P \in \mathbb{R}^{N_{station} \times 2}$和$k$个时间步长的历史气象流序列$\{X^{t-k}, \ldots, X^{t}\}$，学习预测未来m个时间步长的气象流序列$\{X^{t+1}, \ldots, X^{t+m}\}$。

研究对象——气象预测任务

气象预测任务——复杂时空建模任务

- **时序建模**——捕捉单一站点要素随时间的非线性演化趋势
- **空间关联关系建模**——挖掘不同地理坐标点之间的动态物理影响与高阶交互

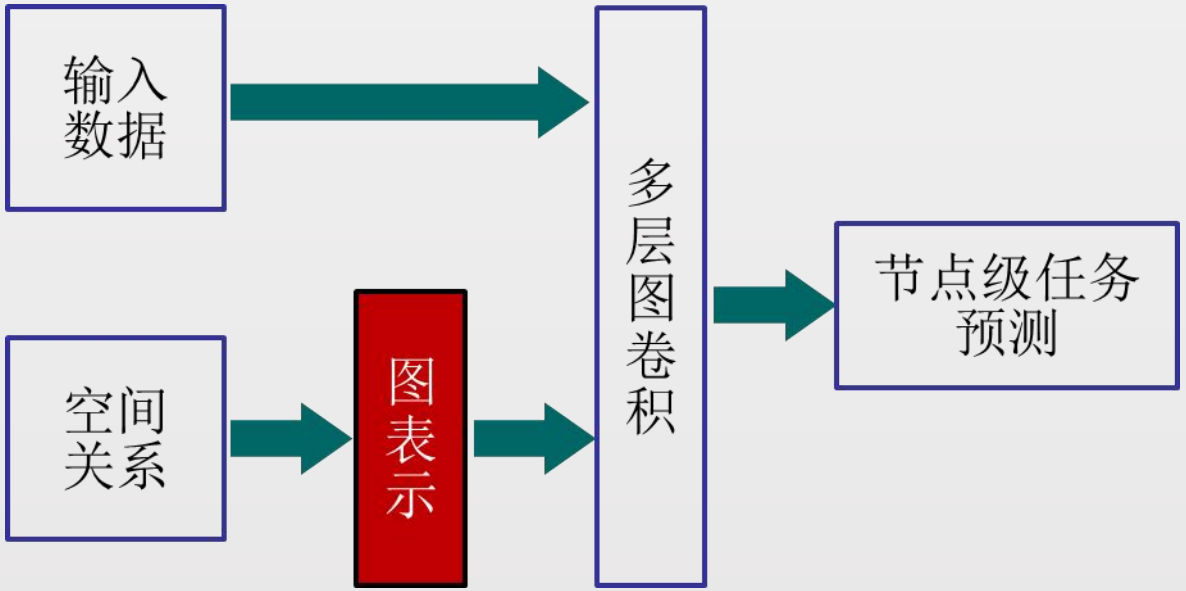

研究内容——基础概念

Kolmogorov-Arnold Networks

--基于Kolmogorov-Arnold表示定理：任何连续函数都可分解为一组一维函数的组合

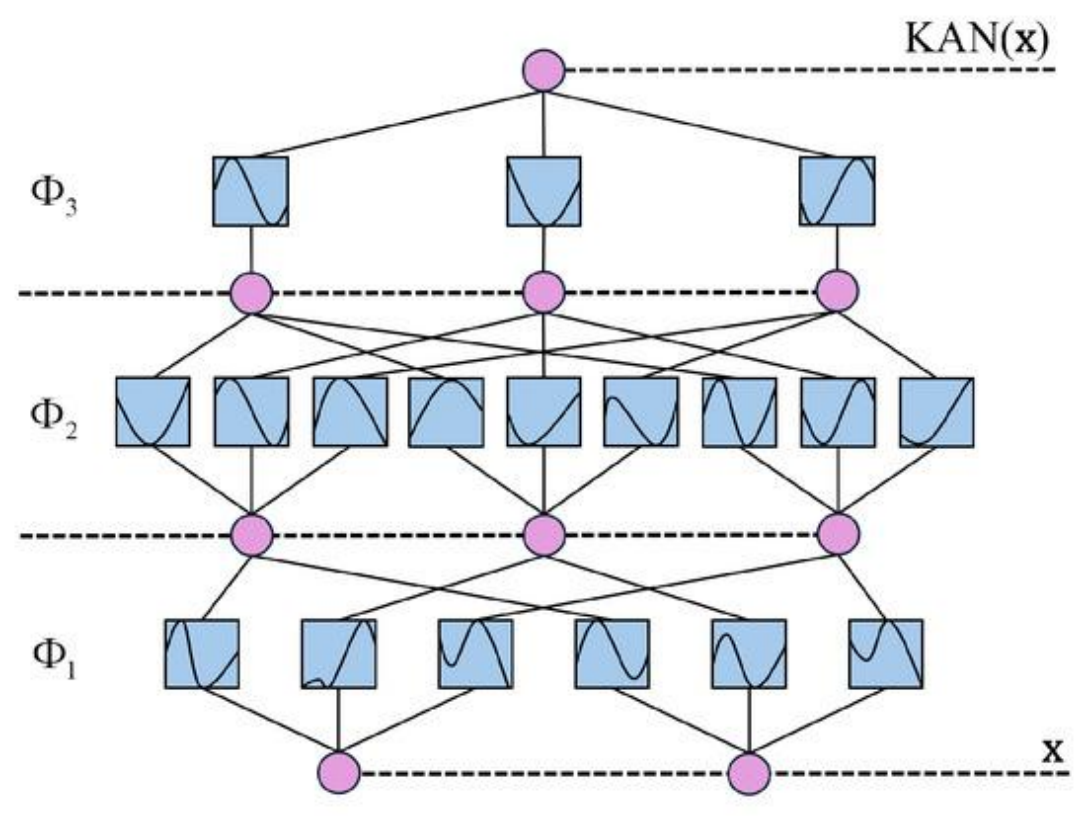

- **核心可解释性**
  - KAN网络结构本质上是一维函数的加权组合
  - 可视化每个一维函数的形状，理解特征对输出的贡献
- **相比传统深度网络 (Transformer, MLP)**
  - 不再是黑箱式非线性映射
  - 对输入特征的影响更直观

研究内容——基础概念

Hypergragh Networks

--扩展图神经网络的深度学习模型，通过在超图中建模高阶关系，实现对复杂多实体交互的高效表示和预测

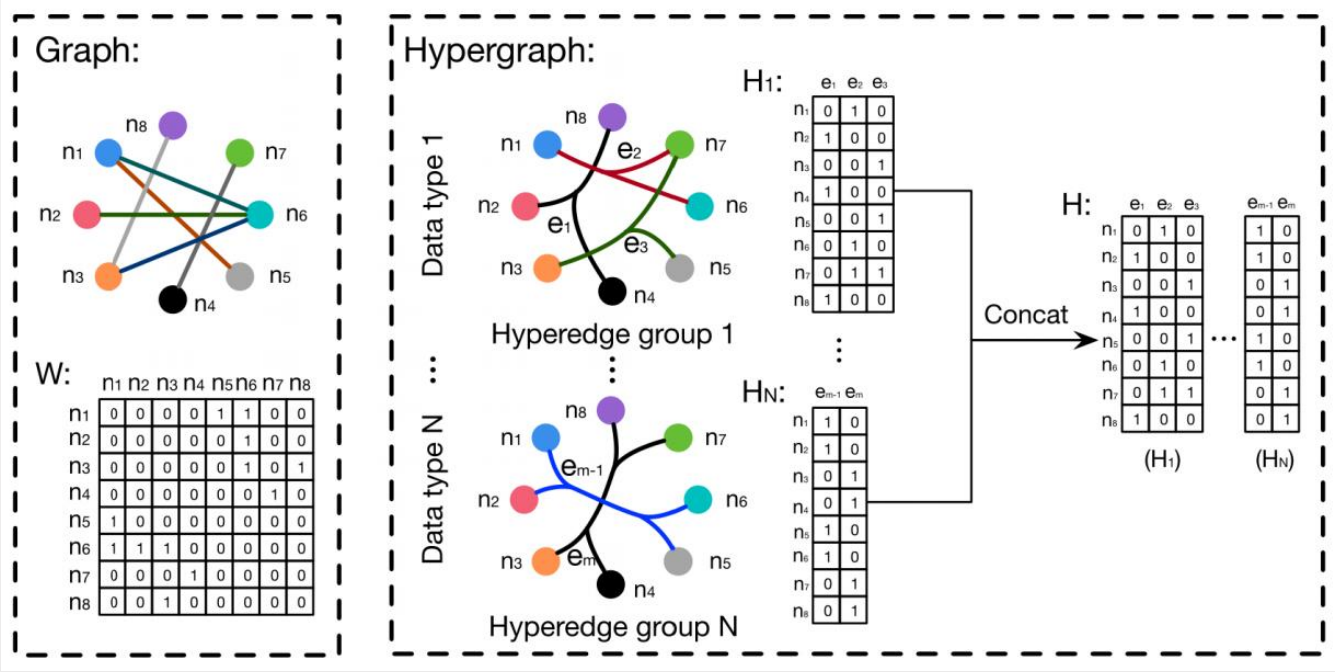

传统图结构的**局限性**：

- 只能建模二元关系，即边只能连接两个节点。
- 邻接矩阵 W 只描述节点之间是否相连，缺乏对“关联原因”的刻画。
- 模型解释性有限：难以追溯预测结果

超图的**可解释性体现**方式：

- 关联矩阵 H可展示：不同节点属于哪些关系群体、哪些高阶模式对预测贡献最大
- 超图神经网络可对超边学习权重，从而解释：“哪些节点组合”真正驱动了预测结果，而不仅仅是节点之间的简单连接。

研究内容1——基于KAN的气象预测

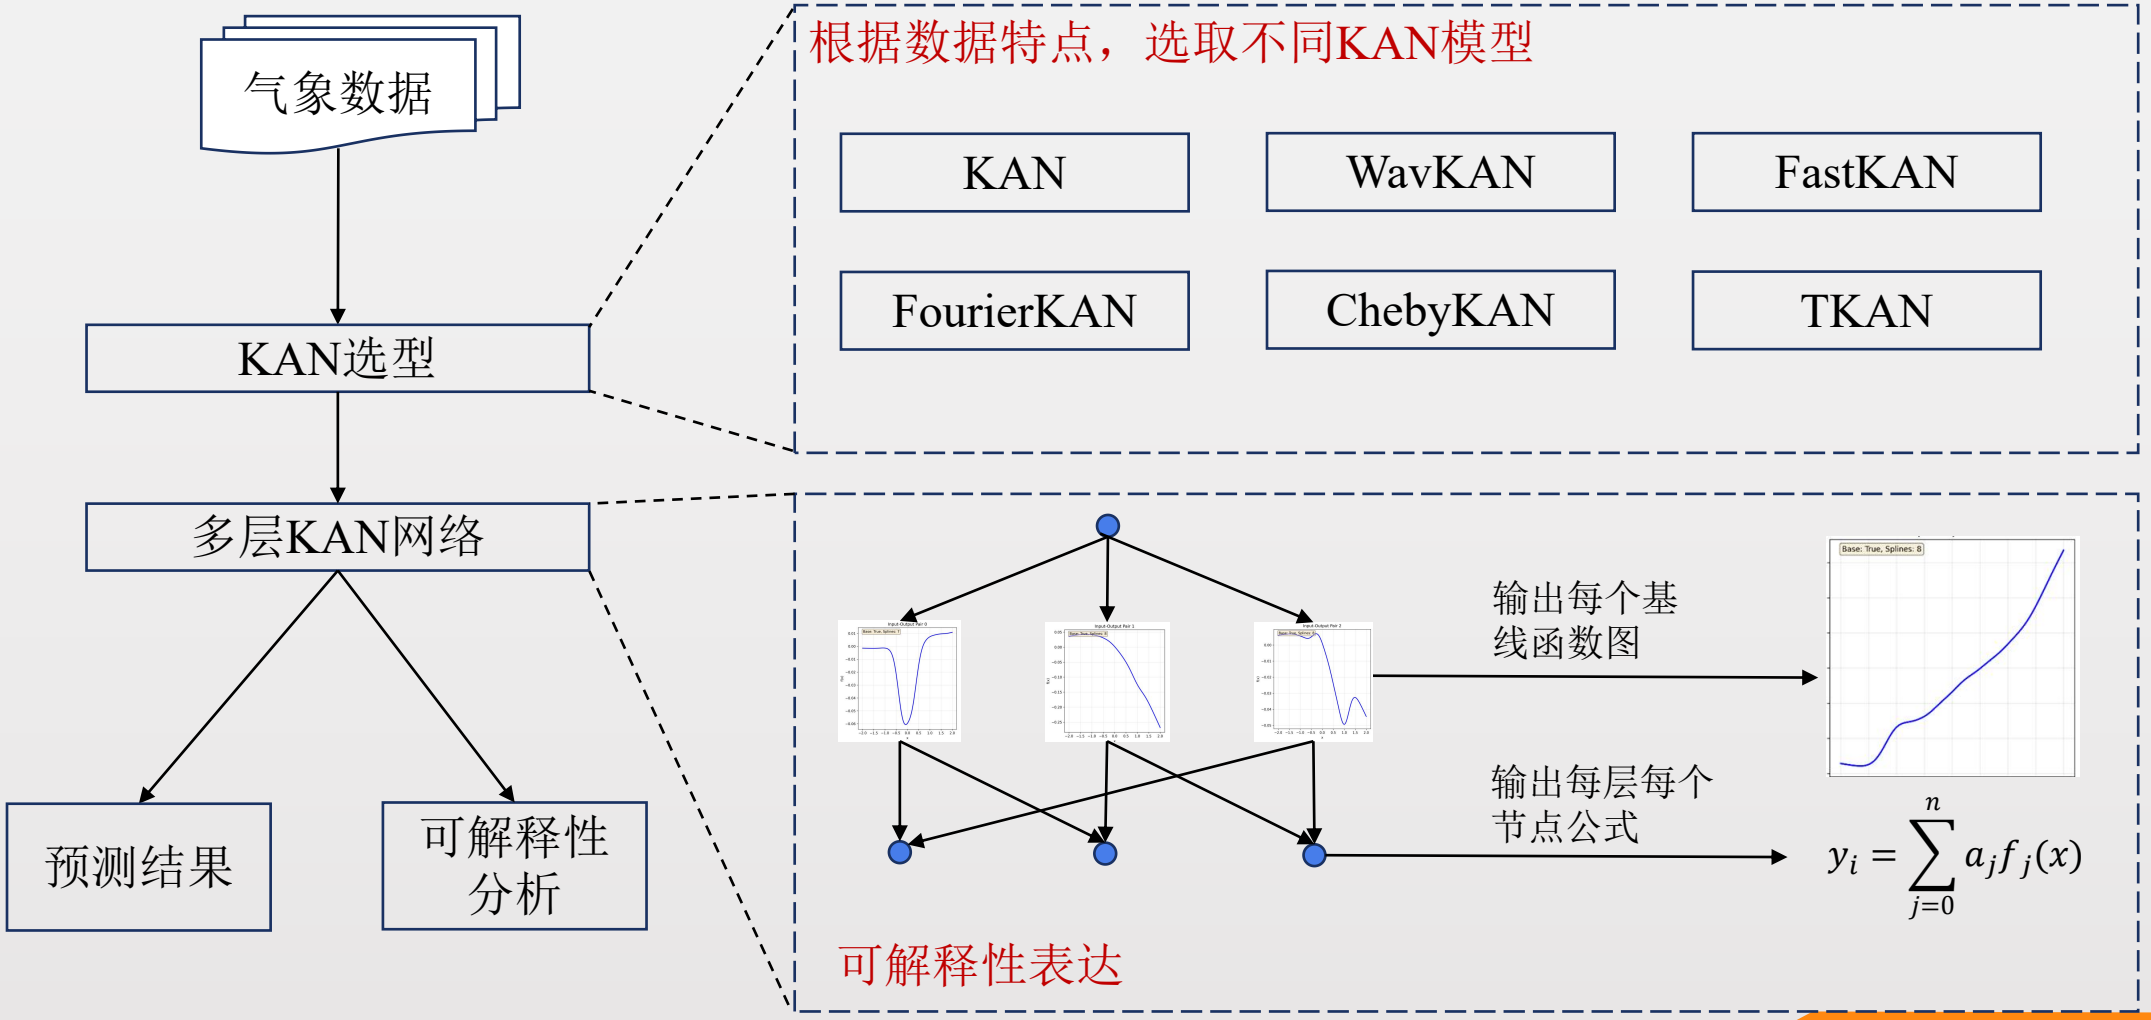

研究内容1——基于KAN的气象预测

选取多种KAN作为预测手段

WavKAN：基于小波基的KAN

- 将 KAN 中的可学习函数f(x)用小波基（wavelet basis）展开，适合处理局部变化显著的气象变量

$$f(x) = \sum_{k} c_k \, \psi_k(x)$$

其中，$\psi_k(x)$是小波基函数（如Daubechies），c_k是可学习参数

局部细节表达力强，对突变、边缘敏感。

FastKAN：通过核函数近似实现的快速KAN

- 通过用固定网格的高斯径向基函数（RBF）近似原始 KAN 中的 B-spline 边函数，并利用高度向量化的核函数计算，显著降低 spline 评估的计算开销，提高训练与推理效率。

$$f(x) = \sum_{i=1}^{m} w_i \, exp(-\frac{(x-\mu_i)^2}{\sigma^2})$$

其中，μ_i 为固定网格上的中心点，σ 为核宽度，w_i 为可学习权重。该核函数形式用于近似原始 KAN 中的 B-spline 边函数。

计算高度向量化、显存占用更低，适用于大规模气象数据的高效训练与推理。

研究内容1——基于KAN的气象预测

选取多种KAN作为预测手段

FourierKAN：基于傅里叶基的KAN

- 用正余弦展开表示可学习函数，可捕捉周期性气象规律（昼夜温度周期、湿度日变化等）

$$f(x) = a_0 + \sum_{k=1}^{K} [a_k cos(kx) + b_k sin(kx)]$$

其中，其中a_k, b_k是可学习系数

适合周期性强的气象变量。

ChebyKAN：基于Chebyshev多项式的KAN

- 将可学习函数用Chebyshev多项式展开，具有更稳定的数值性质。

$$f(x) = \sum_{k=0}^{K} c_k \, T_k(x)$$

其中，$T_k(x)$是Chebyshev多项式，c_k是可学习参数

在风速或者温度曲线拟合中表现平滑、稳定、误差小。

研究内容1——基于KAN的气象预测

选取多种KAN作为预测手段

TKAN：与时间序列建模机制结合的KAN

- TKAN将KAN与LSTM结合，专门用于多步/多时段时间序列预测任务。
- 相较于标准KAN的静态输入到输出结构，TKAN引入“时间维度(t)”和“隐藏状态hidden state”来处理序列数据。
- 可用RKAN (Recurring－KAN)层+门控机制构成：

$$\tilde{h}_t = \mathrm{KAN}(x_t, h_{t-1}),\ y_t = g(\tilde{h}_t)$$

其中x_t为当前输入，h_{t-1}为上一时刻隐藏状态；KAN表示将KAN层作用于当前输入与历史状态。

兼具KAN的强表达，可解释能力和序列记忆能力，更适合气象这种有时间相关性的变量。

研究内容1——基于KAN的气象预测

	Temperature		Cloud		Humidity		Wind	
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
KAN	1.4241	1.9413	0.1586	0.2573	5.9847	8.2490	1.6296	2.3712
FourierKAN	1.4290	2.0716	0.1584	0.2563	6.1052	8.7777	1.7123	2.5882
FastKAN	1.7840	2.4206	0.1597	0.2600	6.2127	8.4649	1.6677	2.4165
ChebyKAN	1.4081	1.9075	0.1588	0.2581	6.0087	8.2571	1.6348	2.3749
TKAN	1.0395	1.4736	0.1558	0.2520	5.0434	7.2892	1.5099	2.2336
WaveKAN	**1.0174**	**1.4180**	**0.1549**	**0.2505**	**4.9274**	**7.1407**	**1.5034**	**2.2258**

- WaveKAN与TKAN有较好的评价结果
- FastKAN优化了速度但显著牺牲了预测精度

研究内容1——基于KAN的气象预测

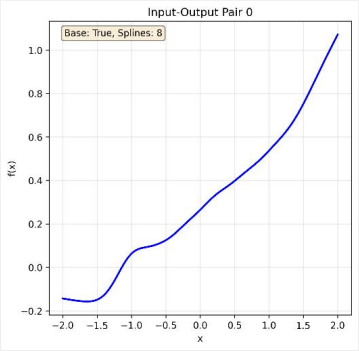

KAN基线函数

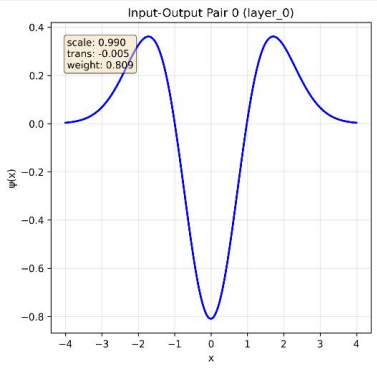

WavKAN基线函数

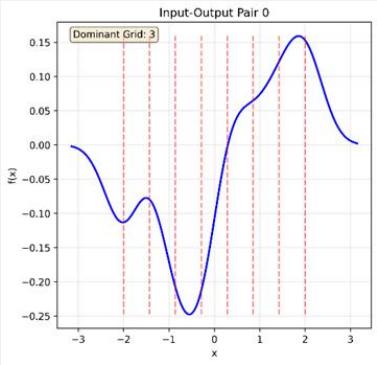

FastKAN基线函数

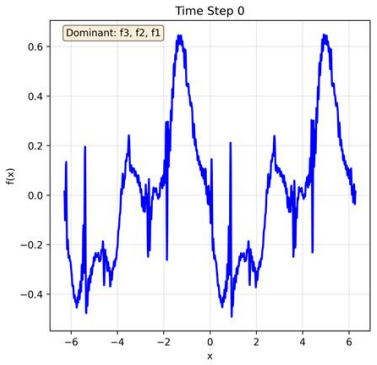

FourierKAN基线函数

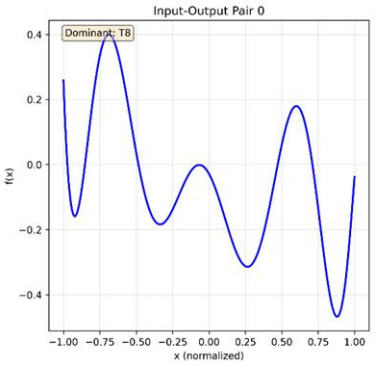

ChebyKAN基线函数

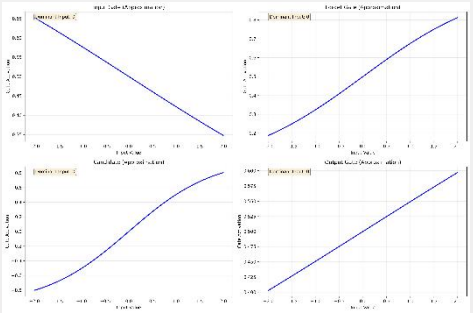

TKAN基线函数

KAN: y0 = 0.6024*SiLU(x0) + 0.1947*B0_3(x0) + 0.1923*B0_0(x0) + 0.1876*B0_2(x0) + 0.1603*B0_1(x0) + 0.1370*B0_4(x0)

WavKAN: y0 = 0.8094*((x0--0.005)/0.990)^2-1)*exp(-0.5*((x0--0.005)/0.990)^2)

FastKAN: y0 = 0.4405*SiLU(x0) + -0.1796*RBF(x0--0.29) + -0.1489*RBF(x0--0.86) + 0.1280*RBF(x0-2.00) + -0.1185*RBF(x0--2.00) + 0.0667*RBF(x0-1.43)

FourierKAN: y0 = 0.0041 + -0.0156*cos(1*x0) + -0.3137*sin(1*x0) + -0.0430*cos(2*x0) + -0.1724*sin(2*x0) + -0.1059*cos(3*x0) + 0.0480*sin(3*x0) + 0.0602*cos(5*x0) + 0.0089*sin(5*x0) + 0.0441*cos(4*x0) + -0.0226*sin(4*x0)

ChebyKAN: y0 = 0.1768*T8(x0) + -0.1648*T(x0) + 0.1245*T6(x0) + -0.0808*T4(x0) + -0.0713*T9(x0) T0(x) = 1, T1(x) = x, T2(x) = 2x^2-1, T3(x) = 4x^3-3x, etc.

TKAN:

LSTM Gates:
input_gate = sigmoid(0.0695*x0 + -0.1445*h0 + -0.1780*h1 + -0.1521*h2)
forget_gate = sigmoid(-0.7090*x0 + -0.1183*h0 + 0.1342*h1 + 0.0444*h2)
candidate = sigmoid(-0.4266*x0 + 0.0822*h0 + 0.0952*h1 + 0.1532*h2)
output_gate = sigmoid(-0.0092*x0 + 0.0106*h0 + -0.0568*h1 + -0.0631*h2)

Sub-KAN Layers:
Sub_KAN_0:
y0 = -0.3414*x0 + 0.1245*x1 + spline_0(inputs)

研究内容1——基于KAN的气象预测

- **KAN网络**只考虑了气象数据时间序列潜在的关系，没有考虑多站点间潜在的空间关联

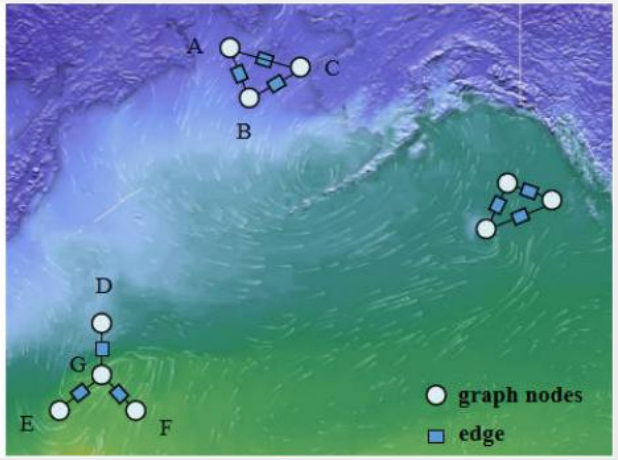

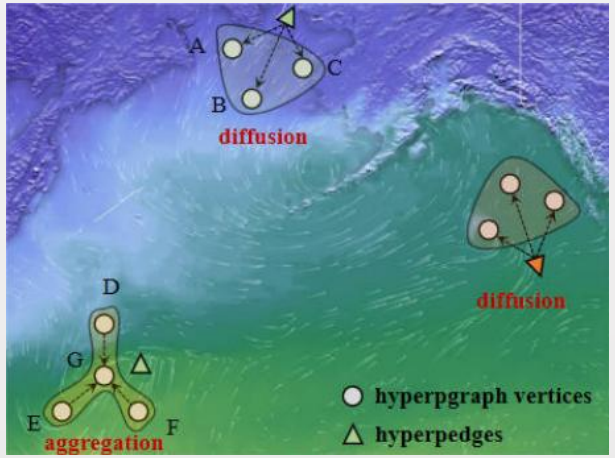

- 引入**超图神经网络**，对多站点间空间上的高阶关联关系进行建模，提高预测准确度

研究内容2——基于超图KAN网络的气象预测

① 利用超图对气象数据之间的空间依赖性进行建模，超图表示能够更有效地对气象现象的高阶聚合进行建模。

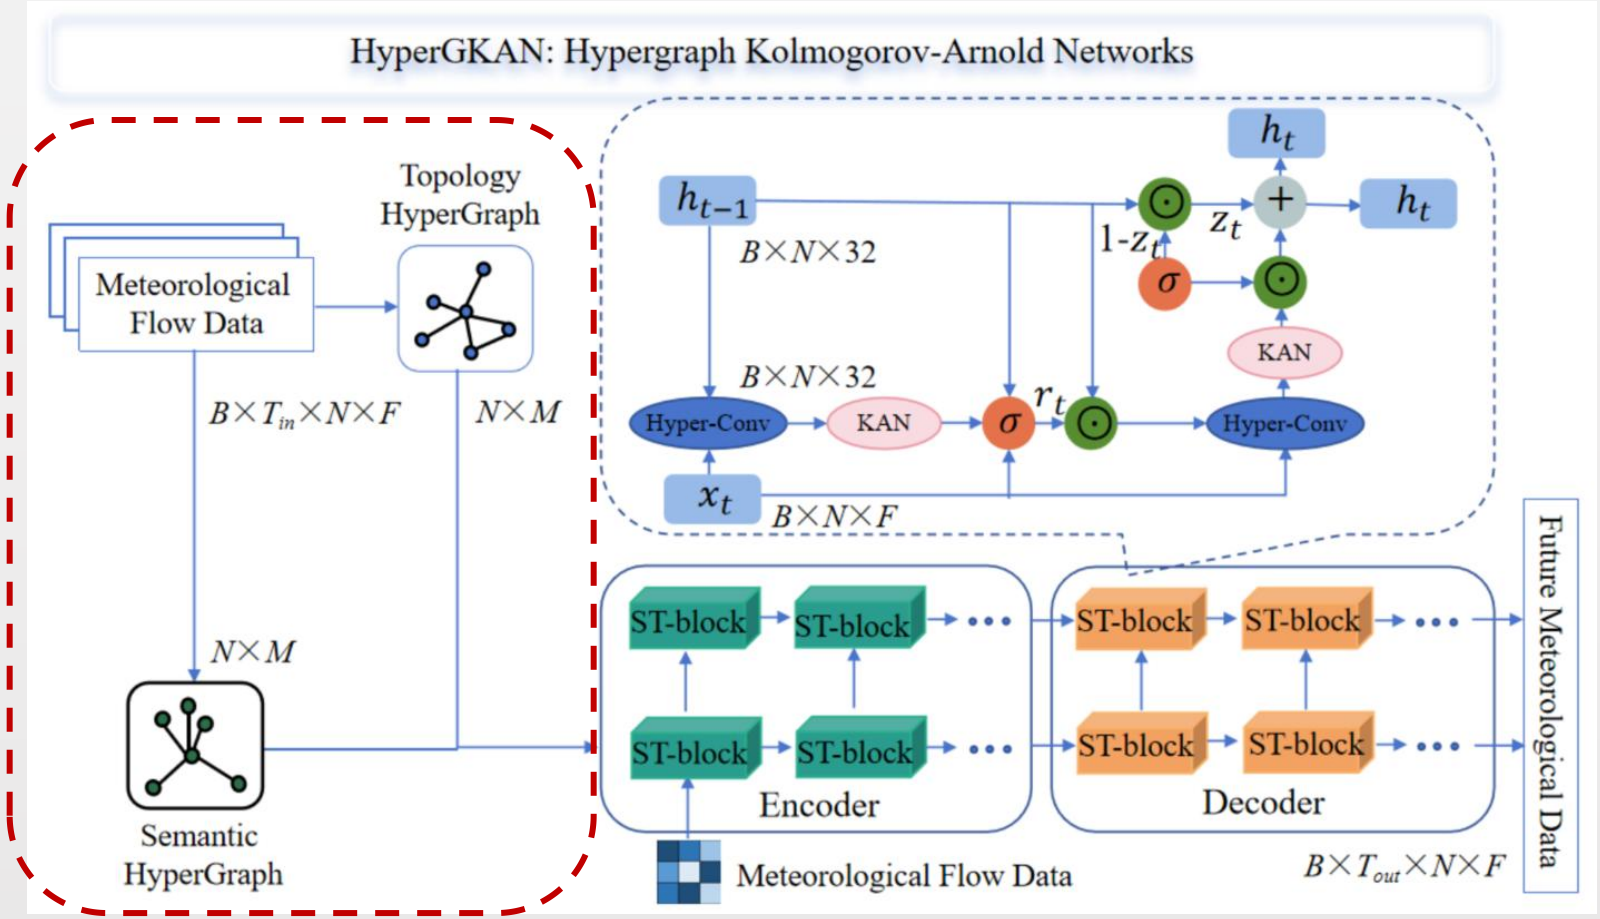

研究内容2——基于超图KAN网络的气象预测

- 依据经纬度信息划分子区域，构建超图结构，挖掘跨站点间气象要素的相似度

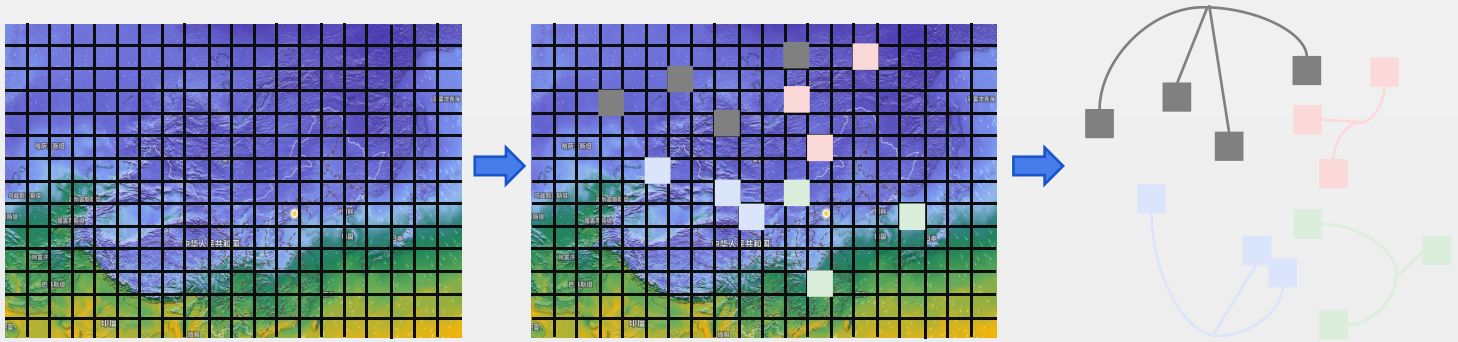

问题：对于部分特殊区域，地势的急剧变化可能导致地理位置相邻的两个站点的气象信息存在较大的差距。

方案：构建超图，获取数据间的复杂高阶关联。

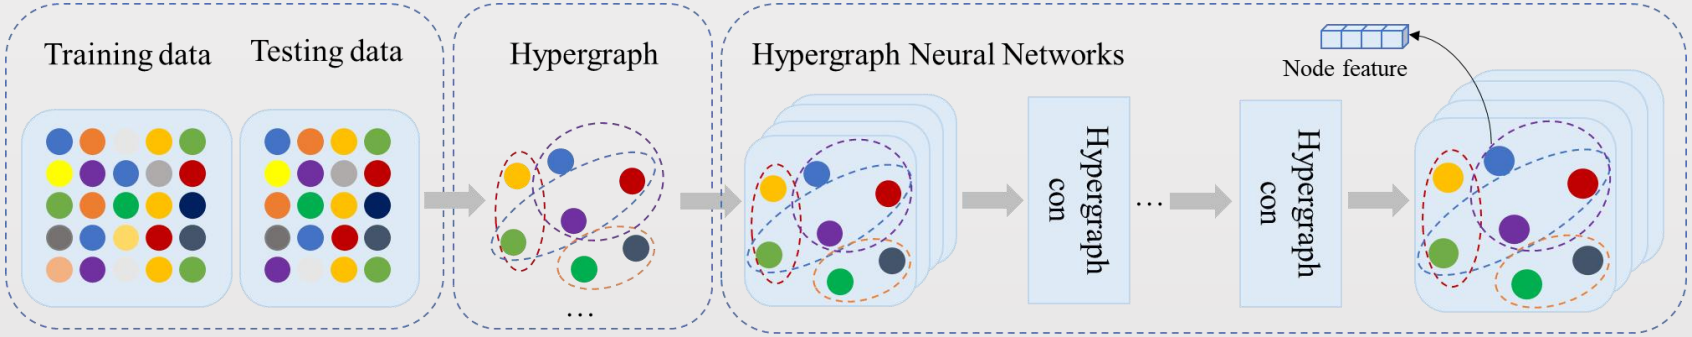

研究内容2——基于超图KAN网络的气象预测

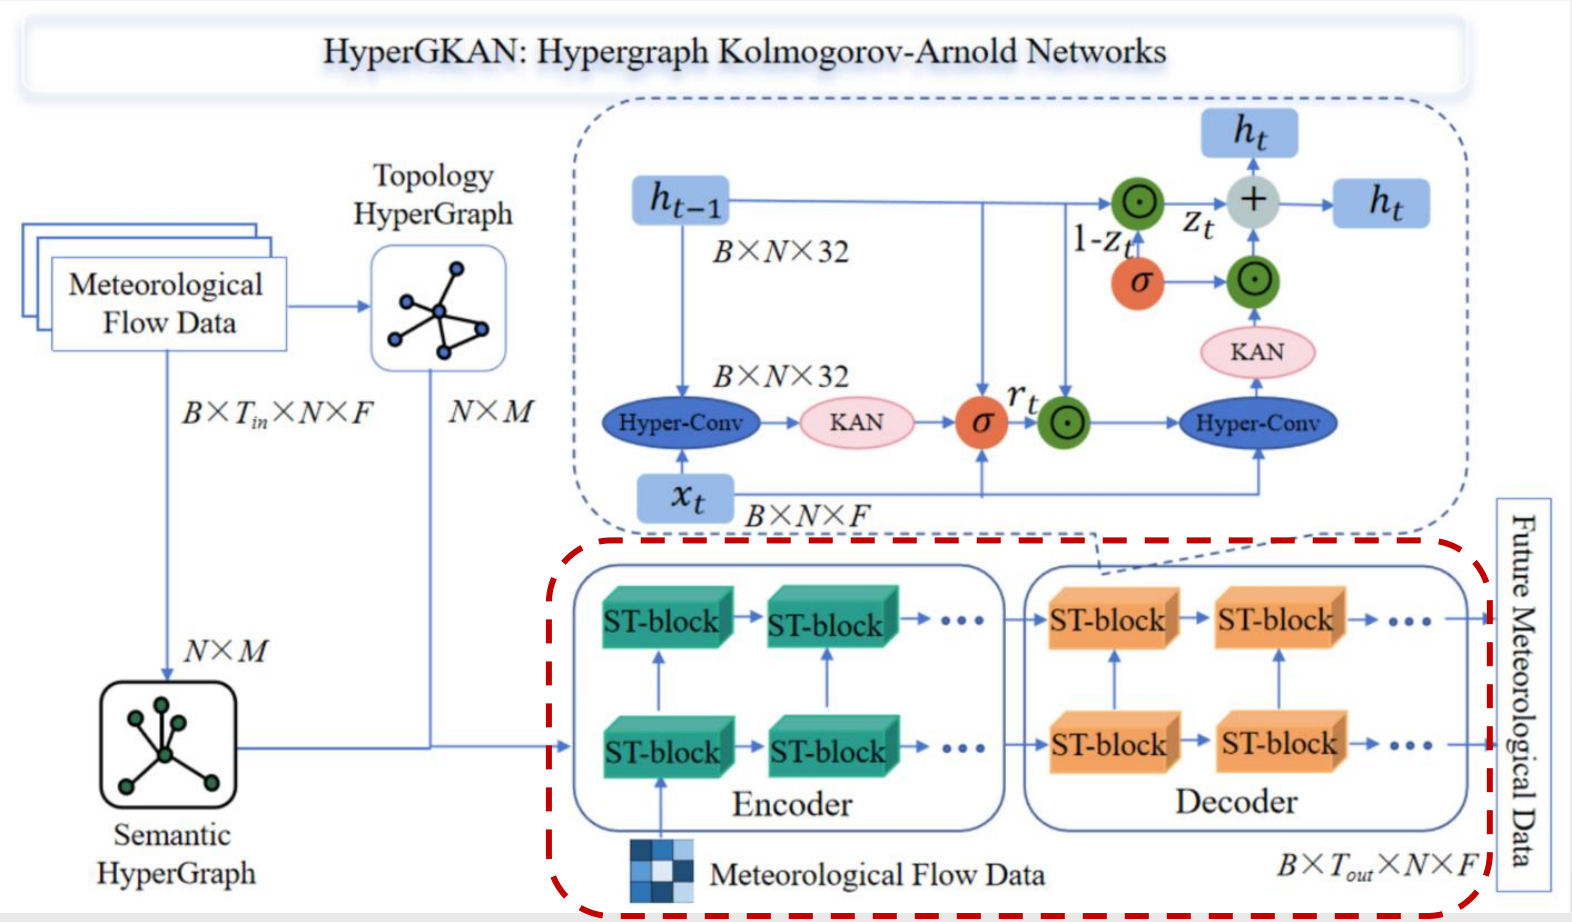

② 提出了一种新的**多信息时空超图学习框架**，该框架由**邻域超图**和**语义超图**卷积网络组成，通过聚合相邻和相似的气象数据来捕获空间特征，从而适应大气系统的复杂性。

研究内容2——基于超图KAN网络的气象预测

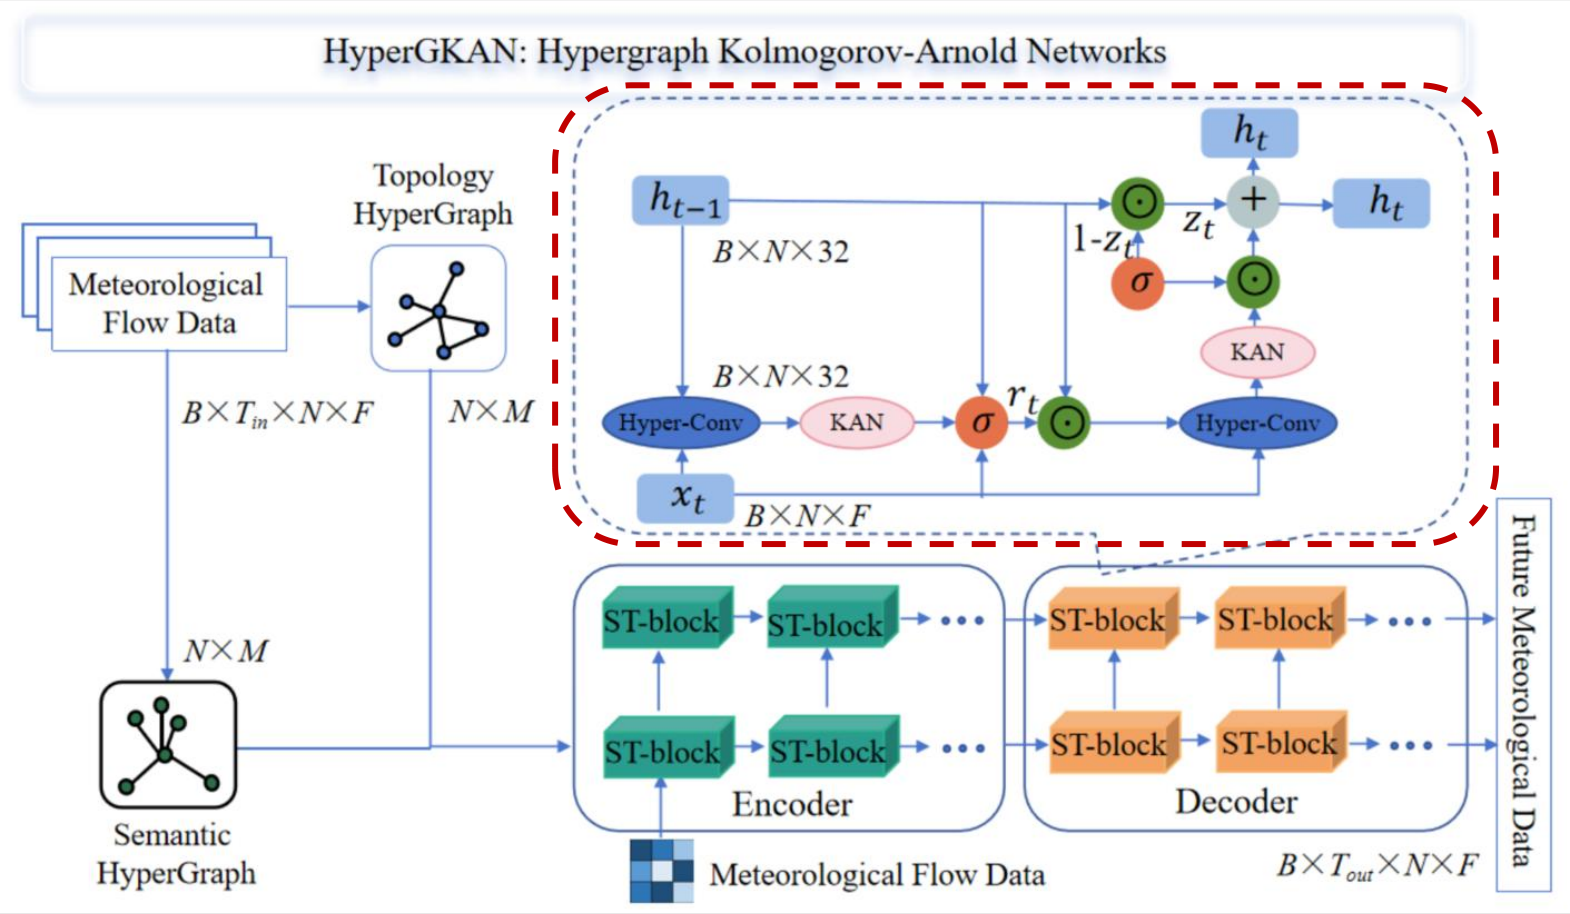

③引入**Kolmogorov-Arnold**网络，利用KAN的独特特性，特别是使用可学习的单变量函数而非固定的线性权重，实现图结构中更动态的特征传播。

研究内容2——基于超图KAN网络的气象预测

基线模型对比实验

方法	Temperature		Cloud cover		Humidity		Wind	
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
GCGRU	1.1757	1.9776	0.1584	0.2547	5.1018	8.0834	1.4102	2.3073
STGCN	3.3083	5.7367	0.2019	0.2954	7.7572	8.1960	3.6477	4.8143
DCRNN	1.1071	1.9391	0.1587	0.2554	5.0717	8.0047	1.3971	2.2758
ASTGCN	1.4766	2.4599	0.1986	0.2948	6.4717	9.0379	2.0883	3.1344
AGCRN	1.2471	1.9095	0.1603	0.2589	5.6321	9.1527	2.3045	3.3044
CLCRN	1.0719	1.7320	0.1495	0.2438	**4.5087**	**7.0046**	1.2362	1.9641
SimpleSTG	**0.8813**	**1.5434**	0.1561	0.2516	4.7718	7.5138	2.4906	3.7017
FCSTGNN	1.0326	1.7248	0.1654	0.2635	5.0428	7.9048	1.4326	2.3179
OUR	0.8942	1.5747	**0.1455**	**0.2420**	4.7059	7.4285	**1.0029**	**1.5702**

- 云量和风速的预测方面表现出色
- 温度和湿度预测方面略有不足

研究内容2——基于超图KAN网络的气象预测

不同预测时长实验

方法	Temperature		Cloud cover		Humidity		Wind	
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
CLCRN(3h)	0.3910	0.7116	0.0925	0.1619	**1.9726**	**3.3682**	0.4975	0.8603
OUR(3h)	**0.3654**	**0.7032**	**0.0902**	**0.1540**	2.0906	3.6335	**0.4954**	**0.8580**
CLCRN(6h)	0.6673	1.1771	0.1202	0.2025	**3.1267**	**5.1698**	0.7966	1.3288
OUR(6h)	**0.6599**	**1.1332**	**0.1114**	**0.1904**	3.6916	6.0886	**0.7896**	**1.3072**
CLCRN(12h)	1.0719	1.7320	0.1495	0.2438	**4.5087**	**7.0046**	1.2362	1.9641
OUR(12h)	**0.8942**	**1.5747**	**0.1455**	**0.2420**	4.7059	7.4285	**1.0029**	**1.5702**

- 多数气象要素预测中**优于CLCRN**
- **时间步长越高**，优势越明显

研究内容2——基于超图KAN网络的气象预测

消融实验

方法	Temperature		Cloud cover		Humidity		Wind	
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
w/o-G	0.9331	1.6360	0.1565	0.2573	4.9931	7.8788	1.5255	2.3876
w/o-Nei	1.0293	1.8047	0.1625	0.2631	5.1798	8.1934	1.3002	1.9141
w/o-Sem	1.0315	1.8369	0.1558	0.2562	5.3106	8.2622	1.1189	1.6337
w/o-KAN	1.0174	1.6688	0.1465	0.2458	4.5067	7.0519	1.2201	1.8922
w/o-Fusion	0.9310	1.6515	0.1561	0.2812	4.9337	7.7684	1.1018	1.6032
OUR	**0.8942**	**1.5747**	**0.1455**	**0.2420**	**4.7059**	**7.4285**	**1.0029**	**1.5702**

- 消融实验验证了各模块在整个框架中的**重要性**
- 移除任何一个模块都会导致预测性能**不同程度的下降**

研究内容2——基于超图KAN网络的气象预测

K-敏感性实验结果

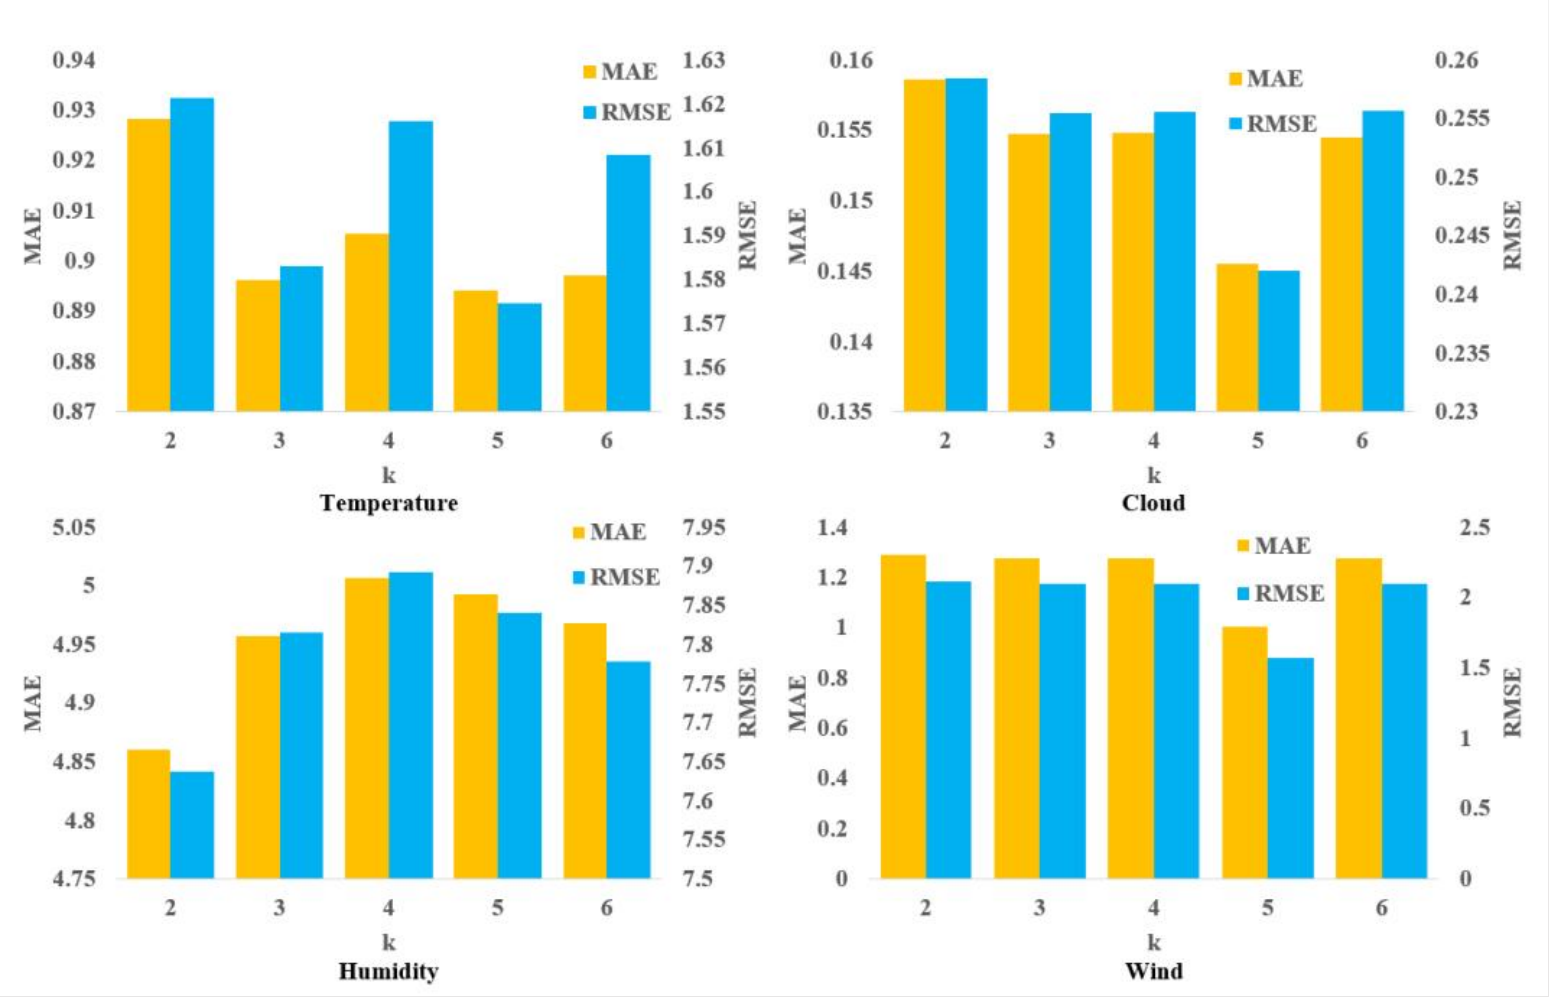

- 超边内的节点数K是构建 K 近邻超图的关键参数
- 较小的K值意味着节点间的成对关系更加局部化
- 较大的K值则使模型能够捕捉节点间更高阶的依赖关系

目 录

- 研究目的及意义
- 研究现状
- 研究对象和内容
- 研究创新性
- 已取得的成果

研究创新性

➢ 基于KAN的可解释性时序建模机制

- 将 KAN 架构引入气象预测，利用可学习的单变量基函数替代传统固定激活函数。
- 突破了传统深度学习模型的“黑箱”局限，实现了预测逻辑的显式化与物理一致性验证。

➢ 基于超图拓扑的高阶空间依赖刻画方法

- 构建了超图 KAN 架构，通过超边机制聚合多站点特征。
- 打破了传统图卷积仅能建模二元关系的瓶颈，实现了大气系统复杂高阶交互关系的精准提取。

目 录

- 研究目的及意义
- 研究现状
- 研究对象和内容
- 研究创新性
- 已取得的成果

已取得的成果

- Tang J, Ma K. “Hypergraph Kolmogorov-Arnold Networks for station level meteorological forecasting,” Physica A: Statistical Mechanics and its Applications, 2025: 130725, doi: https://doi.org/10.1016/j.physa.2025.130725.

敬请各位老师批评指正，谢谢！